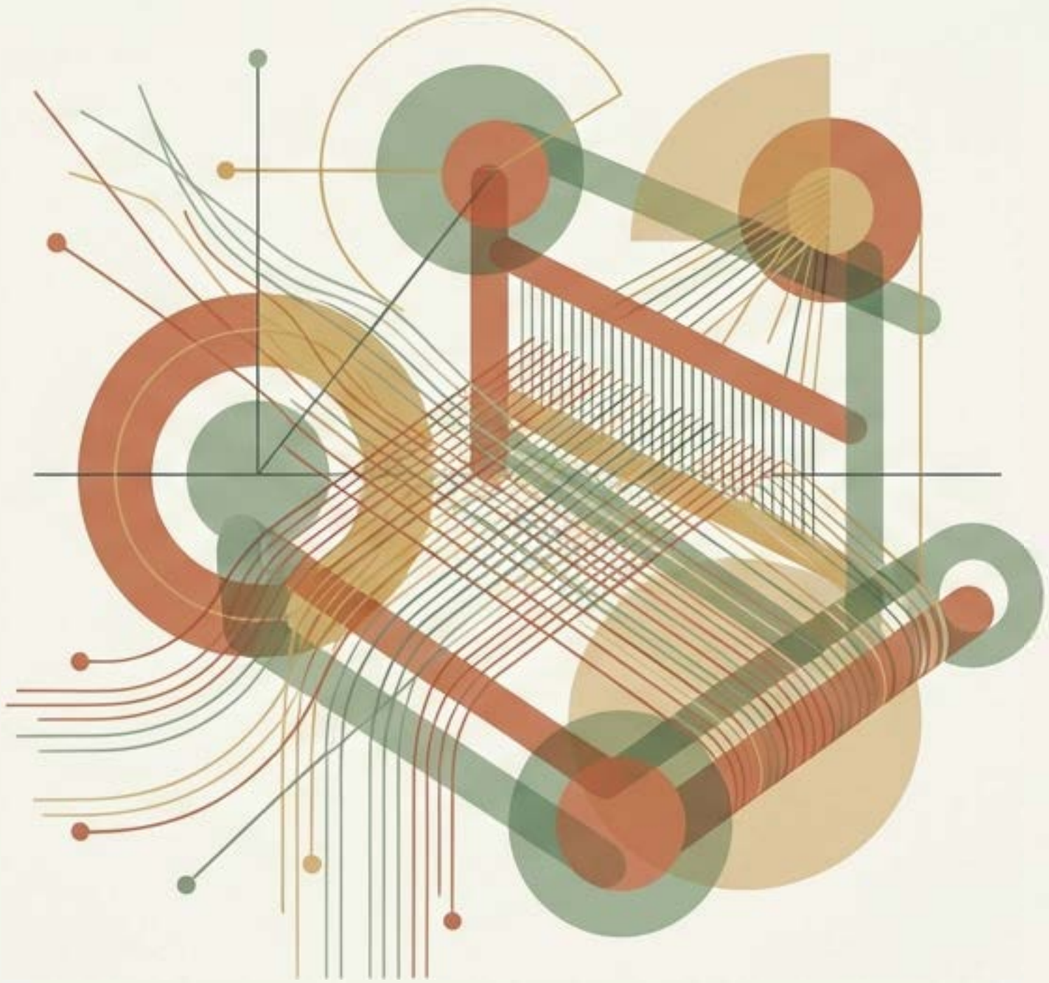

Descifrando la Inteligencia Artificial Generativa

Un viaje desde la magia de la creación hasta la mecánica de los datos.

El núcleo creativo del aprendizaje profundo profundo

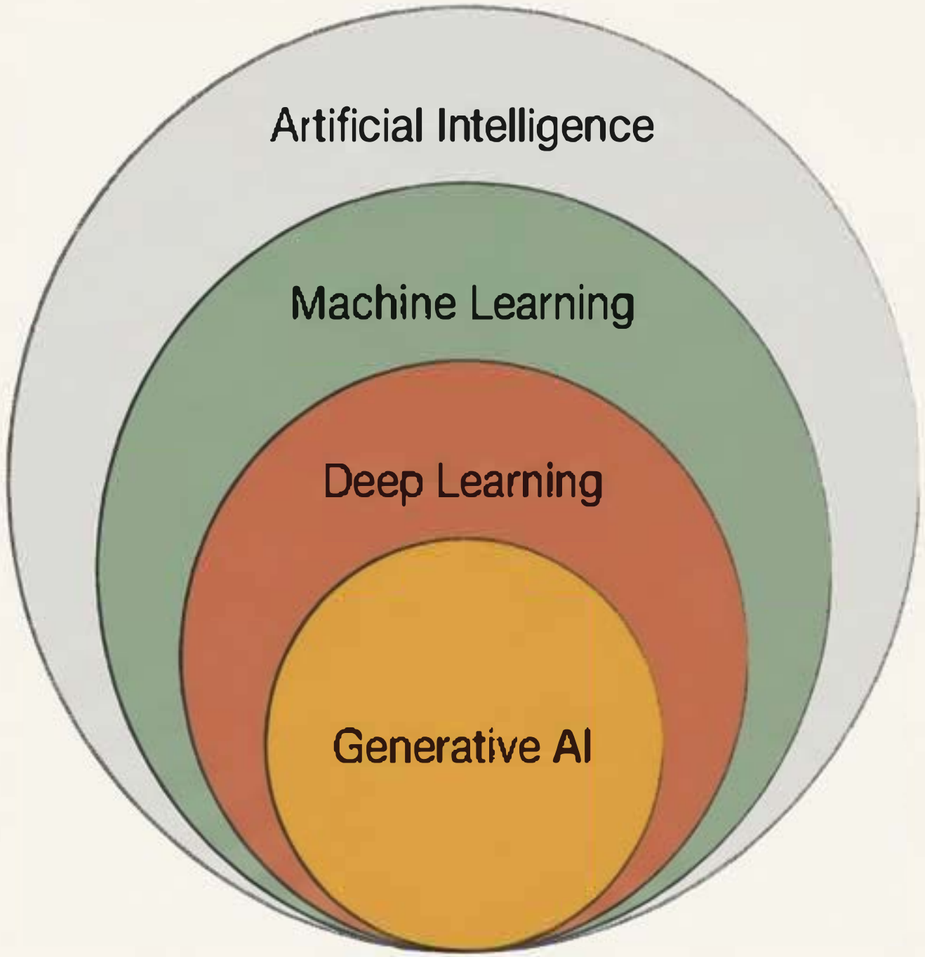

¿Qué es?

Un subconjunto del Deep Learning capaz de crear contenido completamente nuevo.

¿Cómo funciona?

No se limita a clasificar datos existentes (como 'gato' o 'perro'). Aprende los patrones subyacentes en inmensos conjuntos de datos para generar salidas inéditas que comparten esos mismos patrones.

El Cambio de Paradigma:

De analizar el mundo a crear el mundo.

Un motor para infinitas modalidades

Los modelos Multimodales procesan y generan múltiples tipos de datos (texto, imagen, audio) de forma simultánea.

Los Modelos de Lenguaje (LLMs) son motores probabilísticos

Definición: Un modelo de lenguaje es fundamentalmente un modelo estadístico que predice la siguiente palabra.

Escribí al zoológico para que me enviaran una mascota. Me enviaron un...

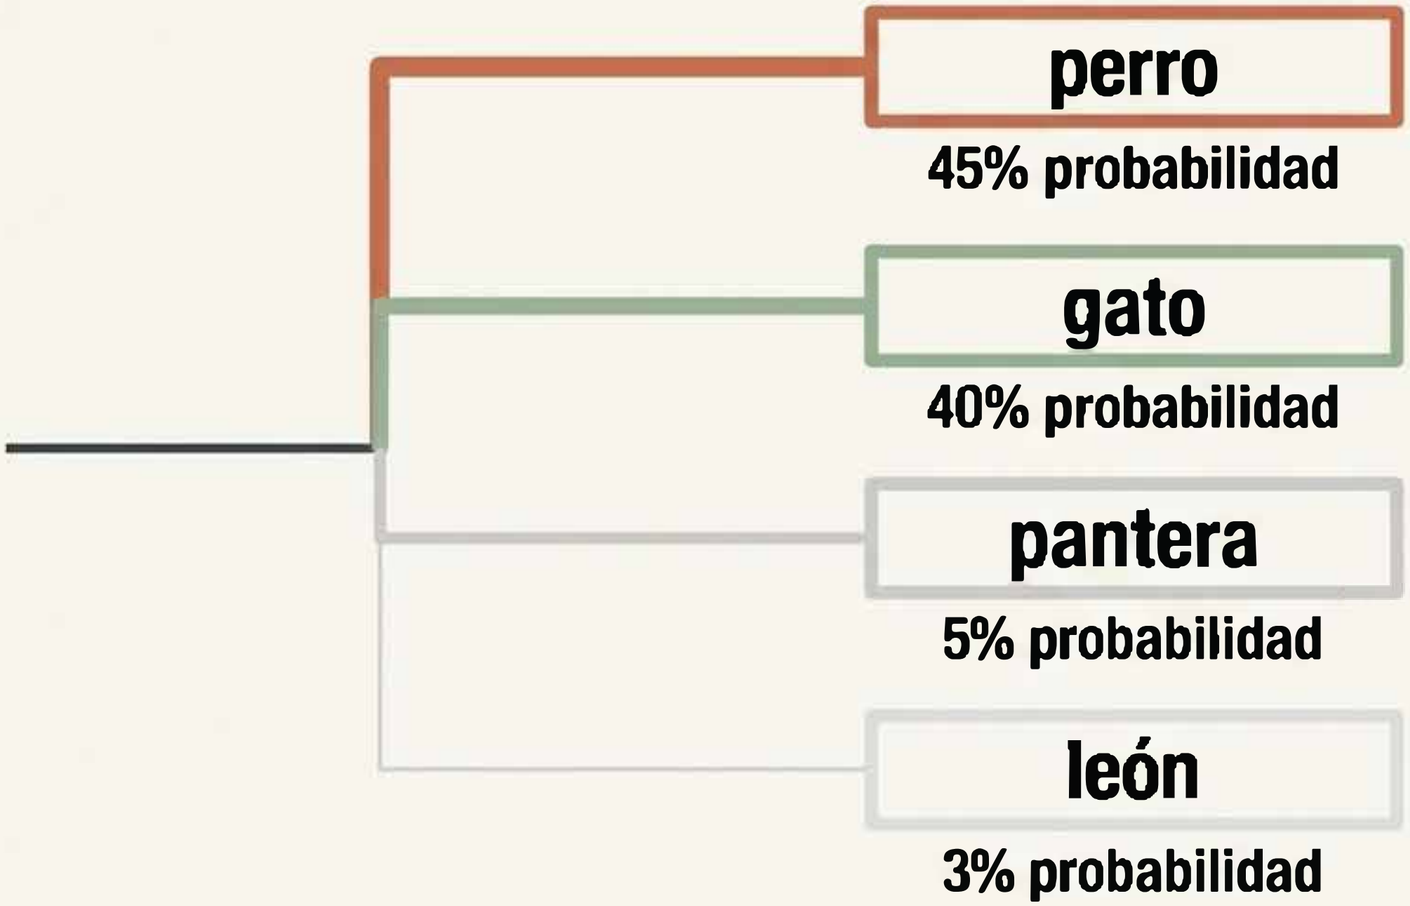

El término “Large” (Grande) se refiere a la inmensa cantidad de parámetros matemáticos utilizados para calcular estas probabilidades.

El ecosistema de los grandes modelos fundacionales

OpenAI

El Pionero Comercial

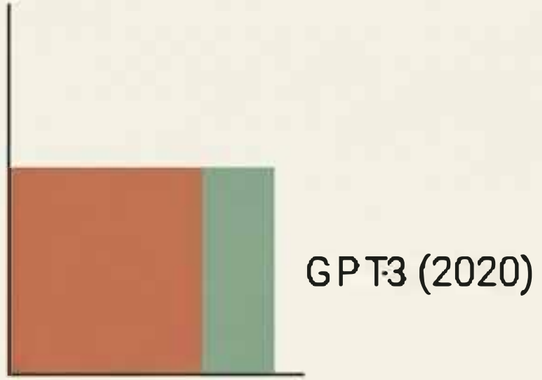

175 Mil Millones de Parámetros

Impacto: Popularizó el aprendizaje 'Few-shot' a gran escala.

Google

Los Arquitectos

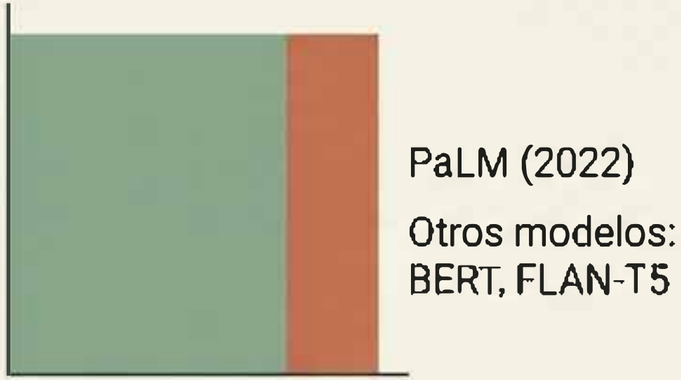

540 Mil Millones de Parámetros

Impacto: Creadores de la arquitectura Transformer fundamental.

Meta

El Movimiento Abierto

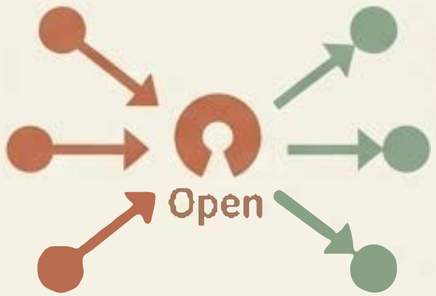

Modelo Destacado: Llama 2

Impacto: Modelos base de código abierto, optimizados para investigación y aplicaciones eficientes.

El salto evolutivo: La Arquitectura Transformer

El Pasado - Redes Neuronales Recurrentes (RNN)

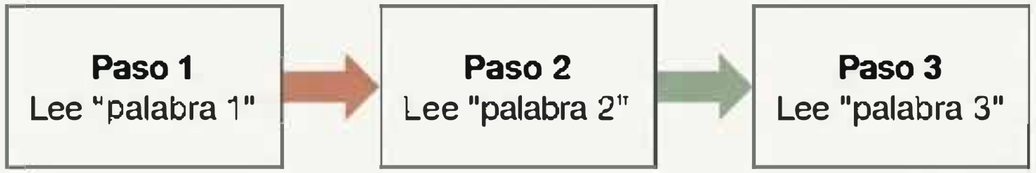

- Procesan los datos de forma secuencial (una palabra a la vez).
- El Problema: Pierden la memoria en oraciones largas y tienen dificultad con dependencias a largo plazo.

El Presente - Transformers (2017)

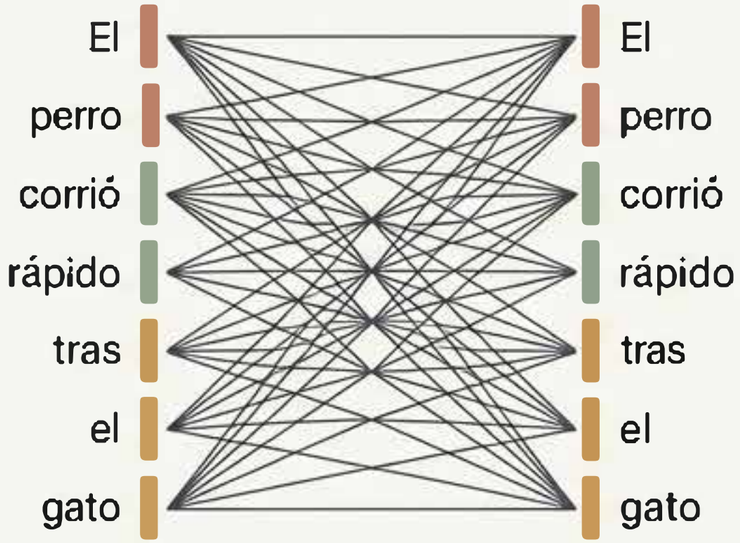

- Analiza todas las palabras de una oración al mismo tiempo.
- Comprende simultáneamente las conexiones entre conceptos, sin importar lo lejos que estén en el texto.

Las máquinas leen rompiendo el lenguaje en Tokens

[Amist] [tad]

[Manzana]

1	1	Los modelos de lenguaje no entienden palabras humanas; procesan unidades matemáticas llamadas tokens.
2	2	Un token puede ser una palabra entera, parte de una palabra, o incluso un signo de puntuación.
3	3	Textos complejos y palabras menos comunes se dividen en más tokens (un promedio de 2 a 3 tokens por palabra).

Dando sentido espacial al texto mediante Embeddings

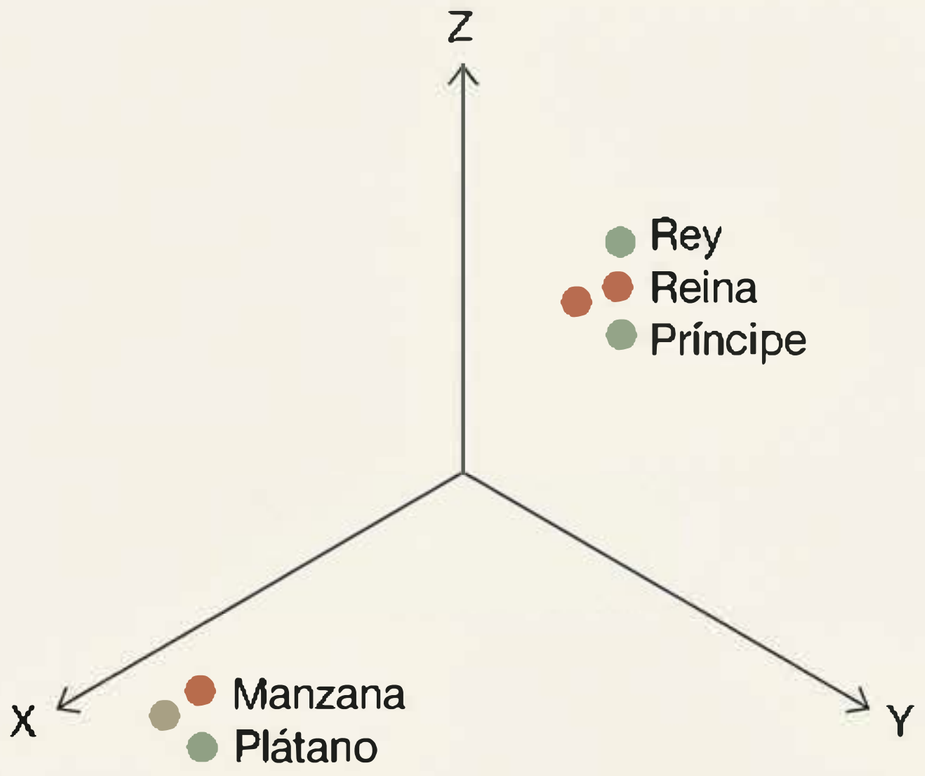

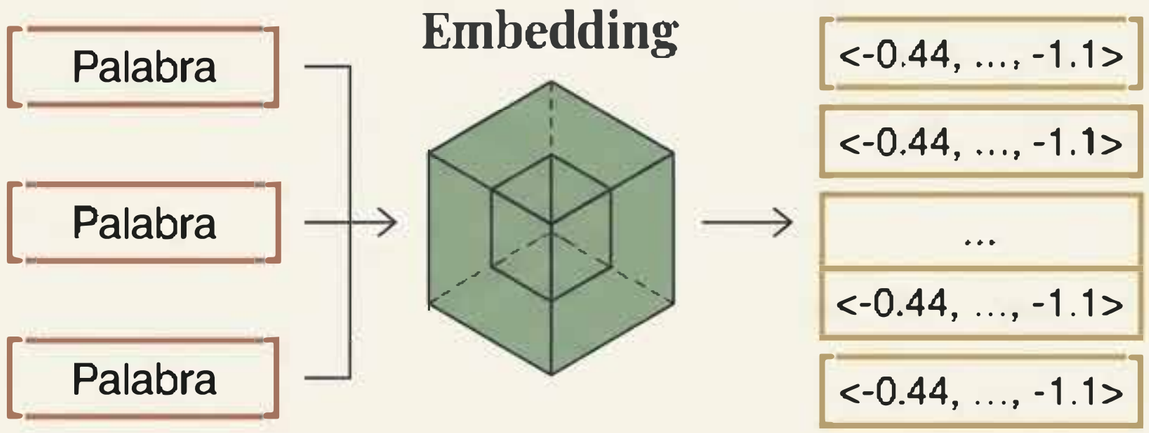

Los **Embeddings** son representaciones numéricas del texto. La magia matemática radica en que palabras con significados similares terminan ubicadas físicamente cerca unas de otras en este gigantesco espacio multidimensional, permitiendo a la máquina calcular el contexto.

El mecanismo de Atención: Tejiendo el contexto

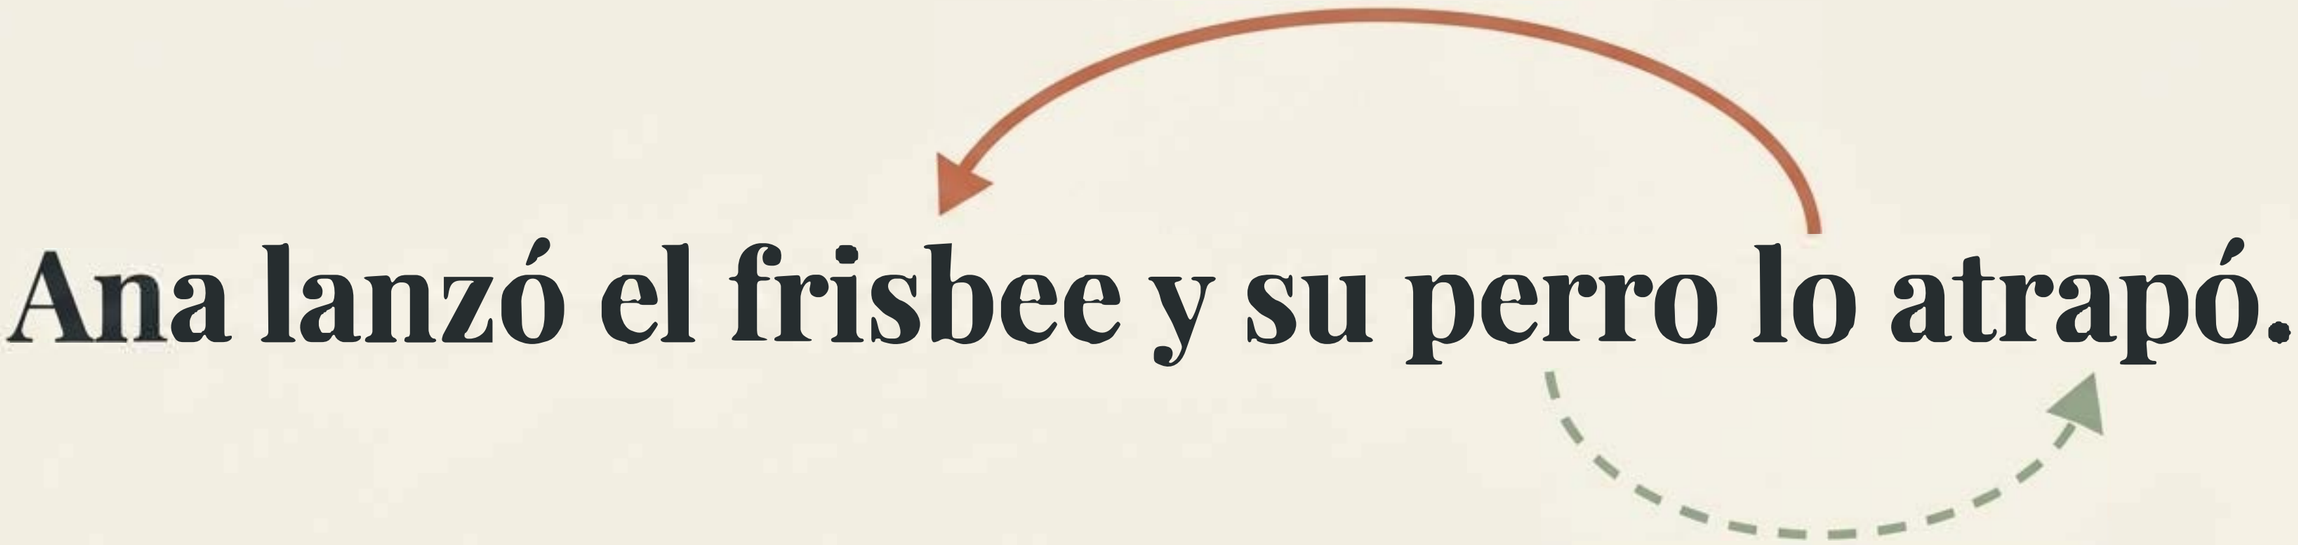

Auto-Atención (Self-Attention):
Determina la relevancia e importancia de cada palabra frente a las demás en la misma oración.

En lugar de solo mirar la palabra ‘lo’, el modelo presta atención a todo el contexto anterior para deducir matemáticamente que ‘lo’ se refiere al frisbee, y no a Ana o al perro.

El motor completo: Codificadores y Decodificadores

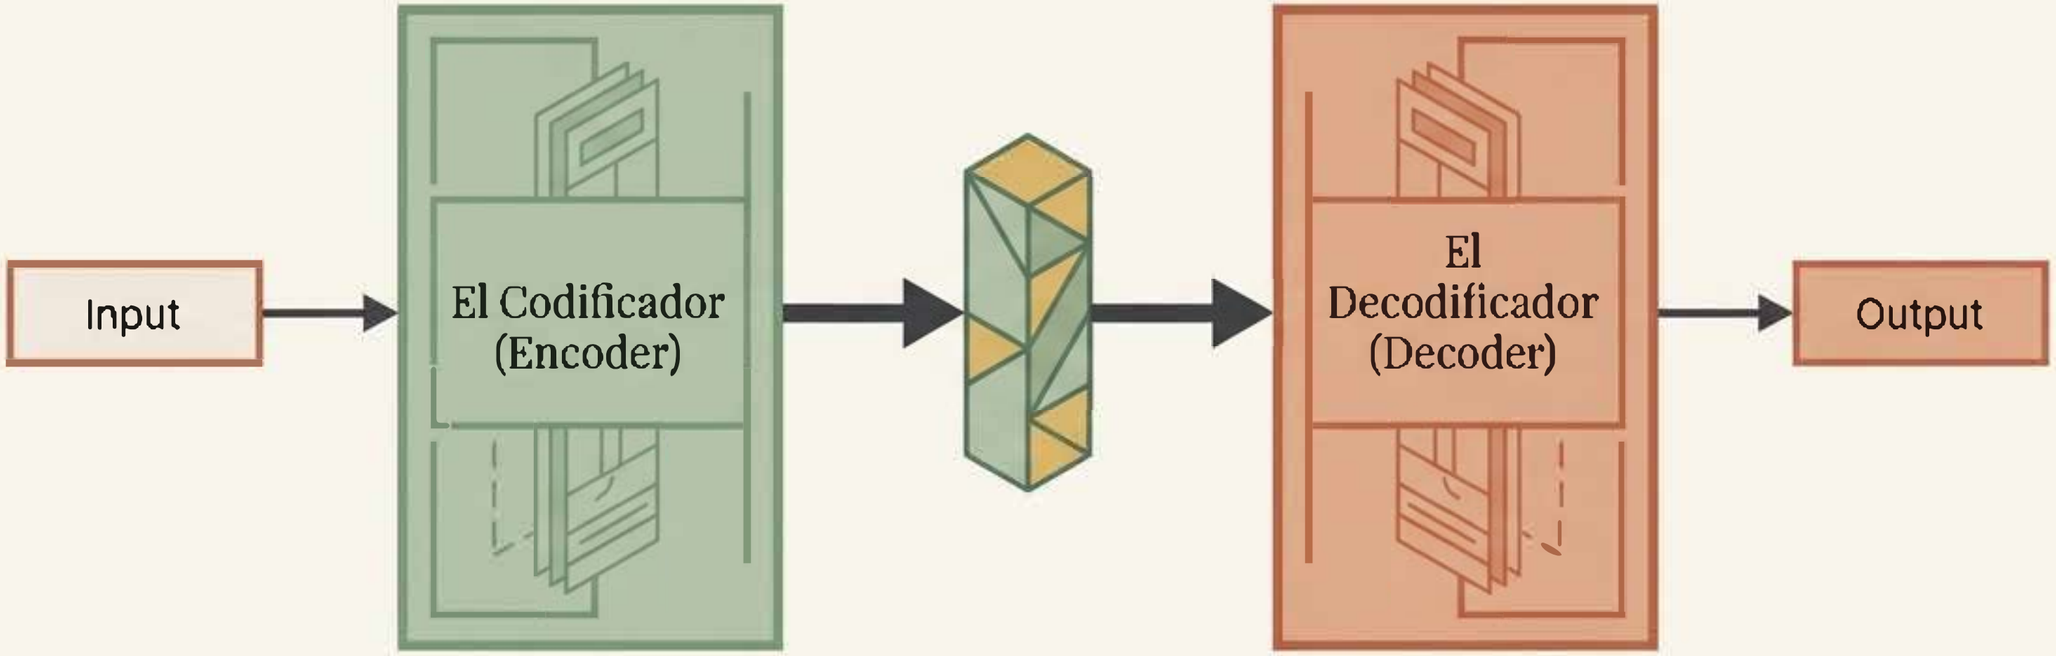

Función: Lee el texto de entrada y lo convierte en Embeddings (vectores de contexto).

Uso principal: Comprensión y clasificación (Ej: BERT).

Función: Toma los vectores matemáticos y genera nuevo texto, prediciendo palabra por palabra.

Uso principal: Generación de texto y modelos de chat (Ej: GPT).

El problema de las Alucinaciones

La convención actual de conducción en los Estados Unidos es conducir por el lado derecho de la carretera… Durante la primera mitad del siglo XX, Estados Unidos adoptó gradualmente el sistema de conducción por el lado izquierdo.

FALSO

Definición: Una alucinación ocurre cuando el modelo genera texto que es sintácticamente fluido pero carece de precisión fáctica.

El Motivo: Los LLMs están diseñados para predecir la siguiente palabra de forma probable, no para buscar la verdad absoluta en una base de datos.

La Solución: Debemos anclar los modelos con herramientas de personalización.

Tu matriz de control: Personalizando la IA

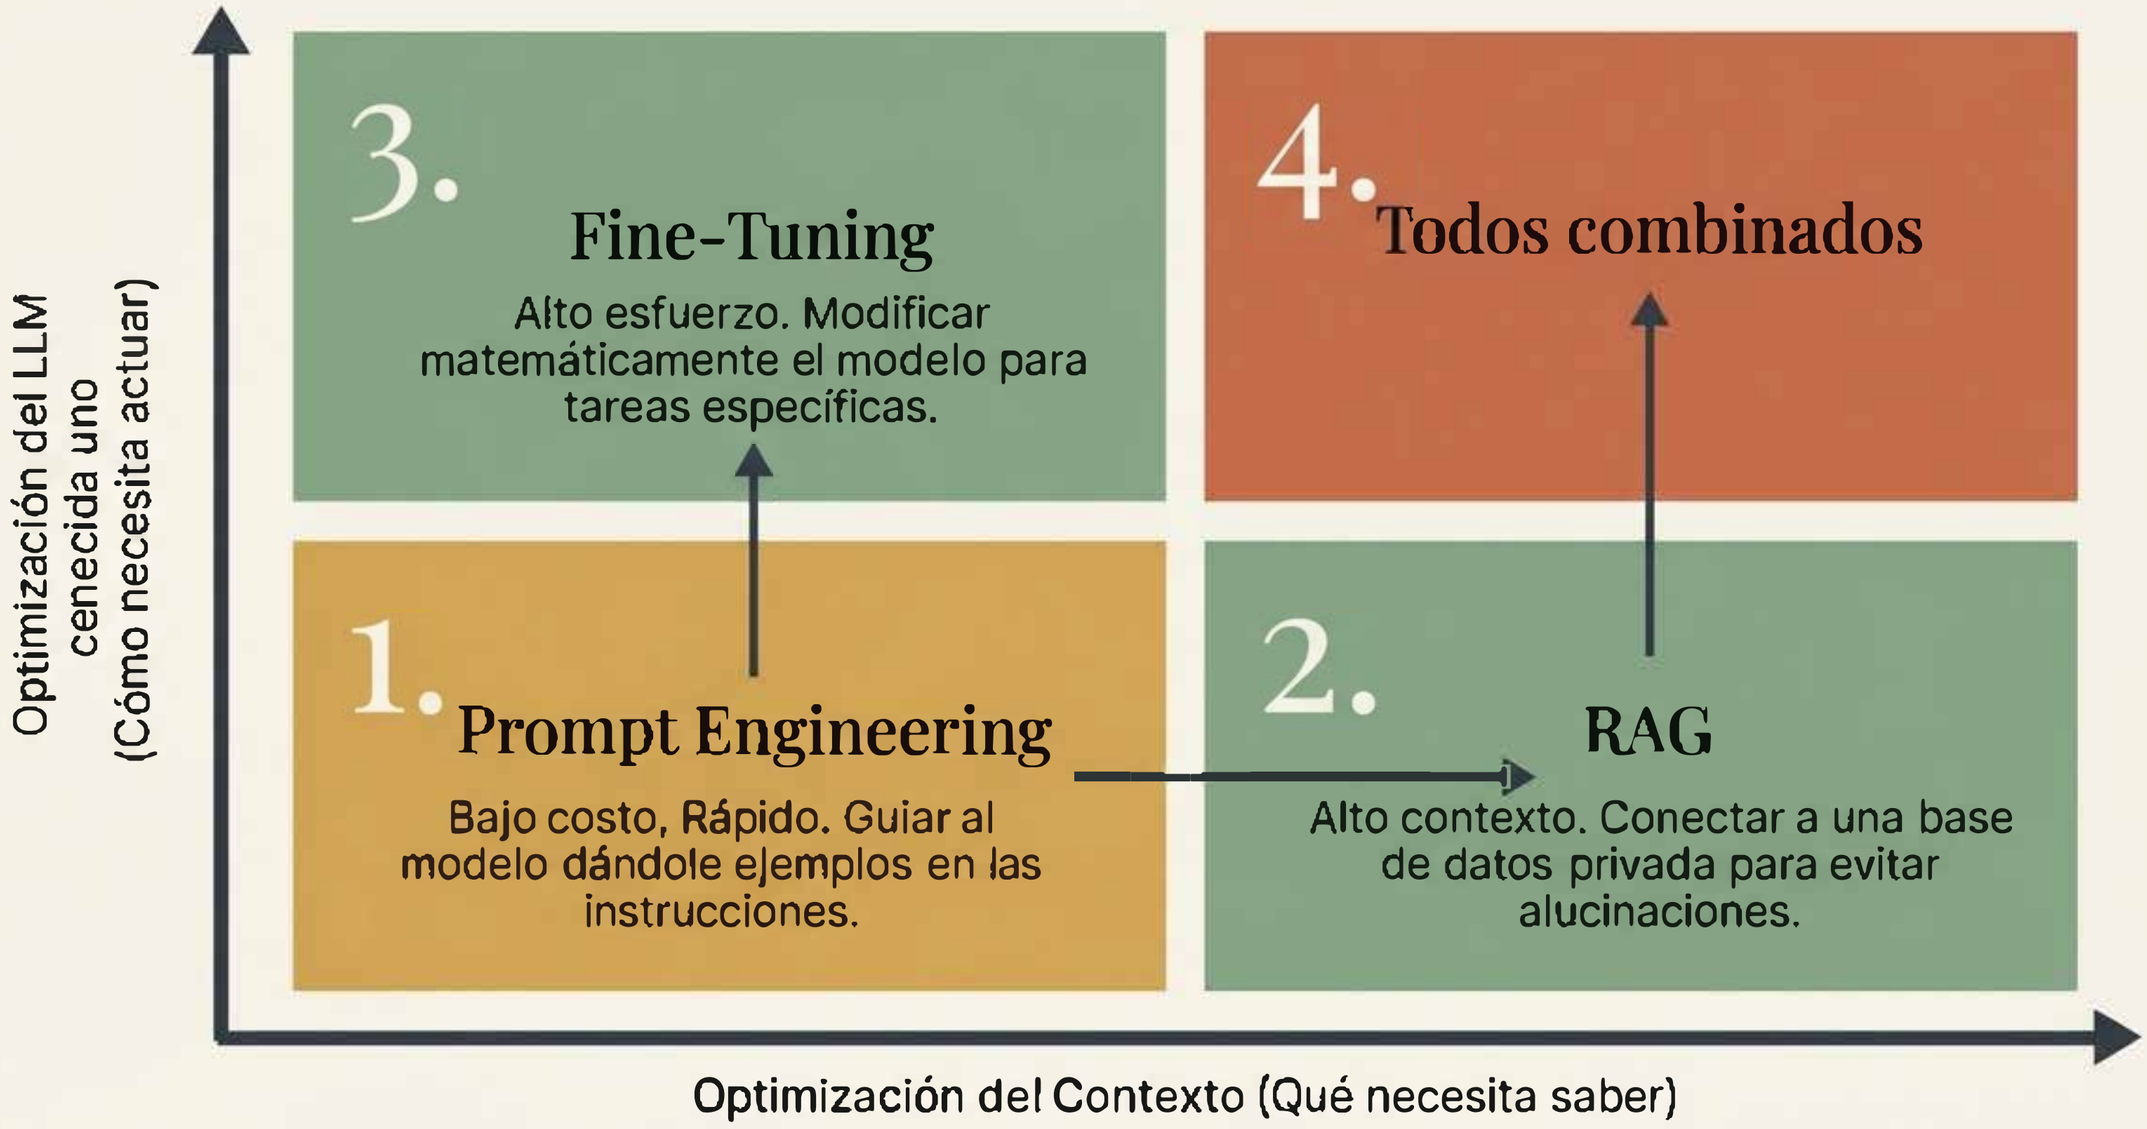

Nivel 1: Prompt Engineering y Aprendizaje en Contexto

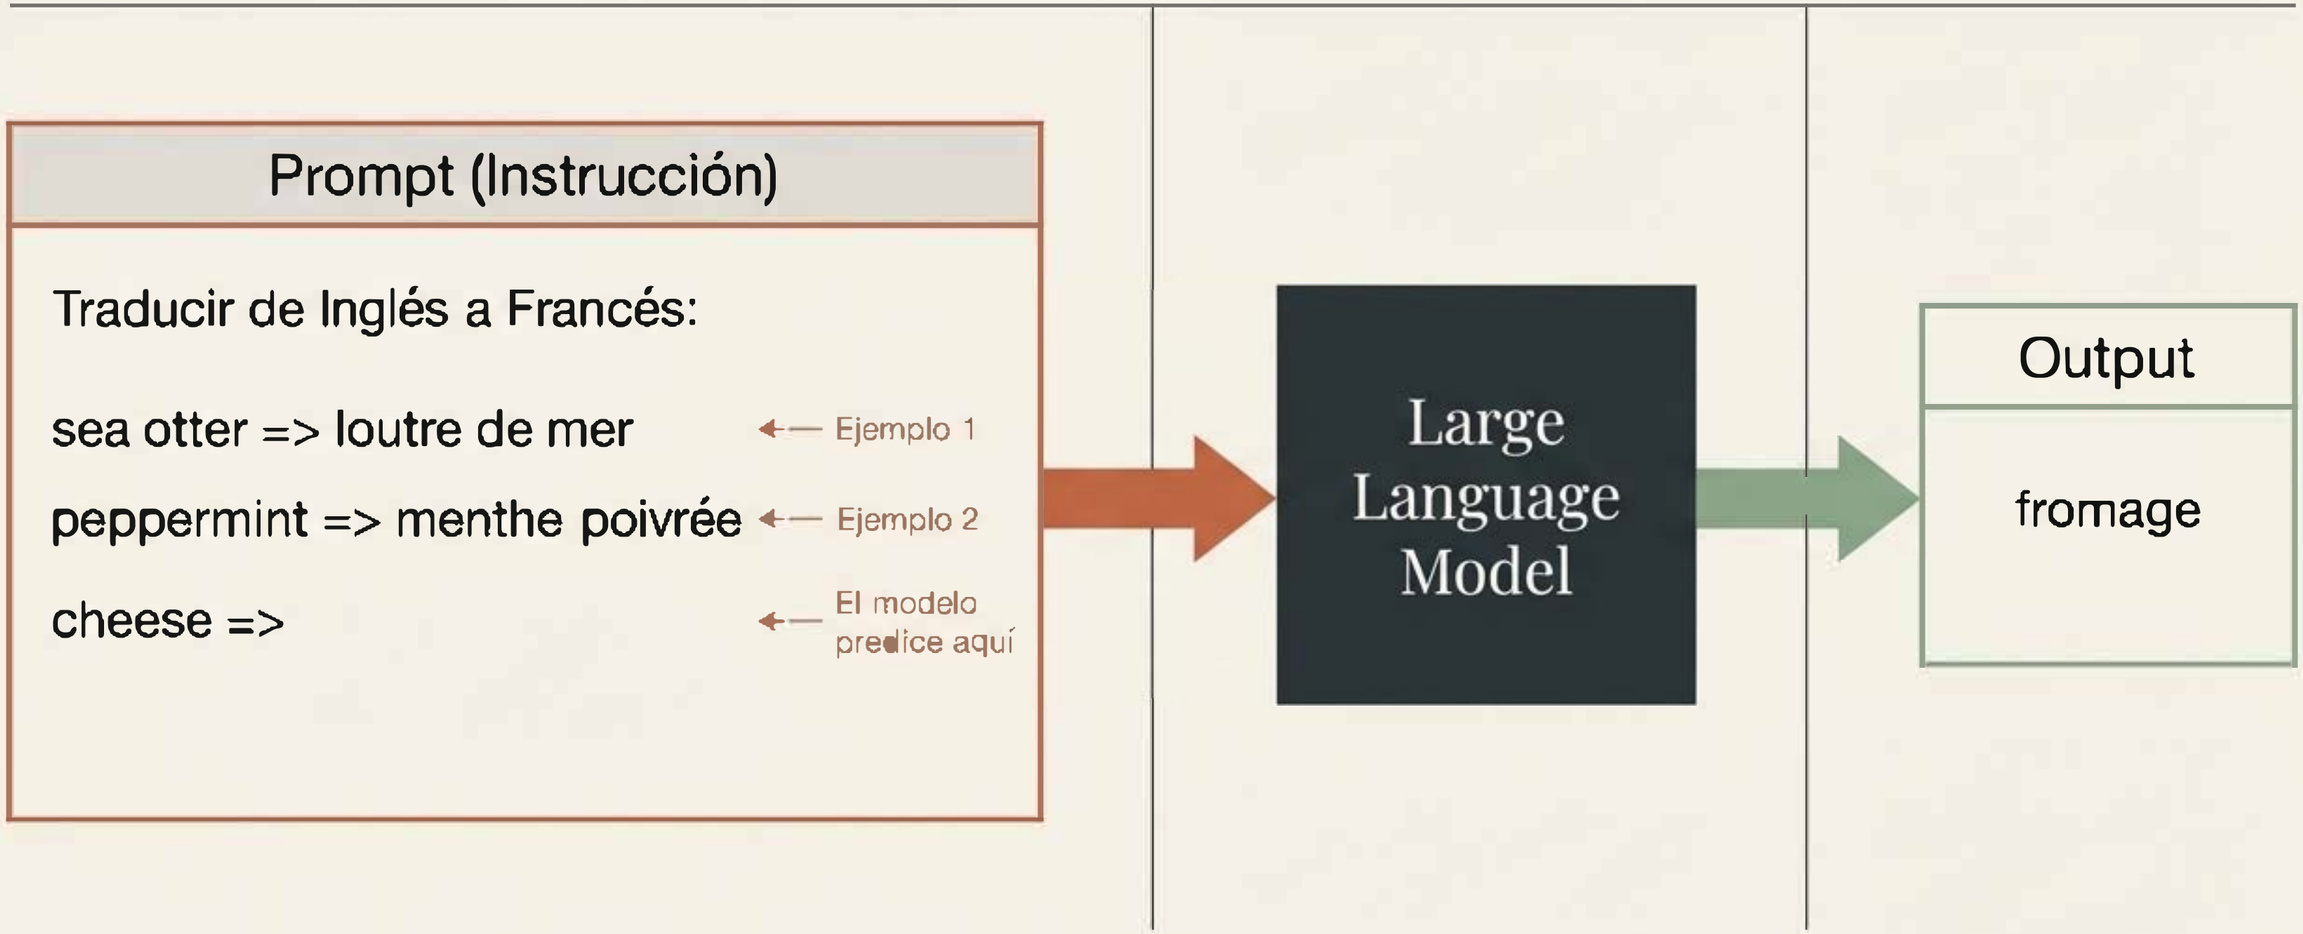

El aprendizaje en contexto (In-Context Learning) condiciona al LLM dándole demostraciones explícitas de la tarea que debe completar antes de pedirle que genere la respuesta, todo sin alterar el código subyacente del modelo.

Nivel 2: Generación Aumentada por Recuperación (RAG)

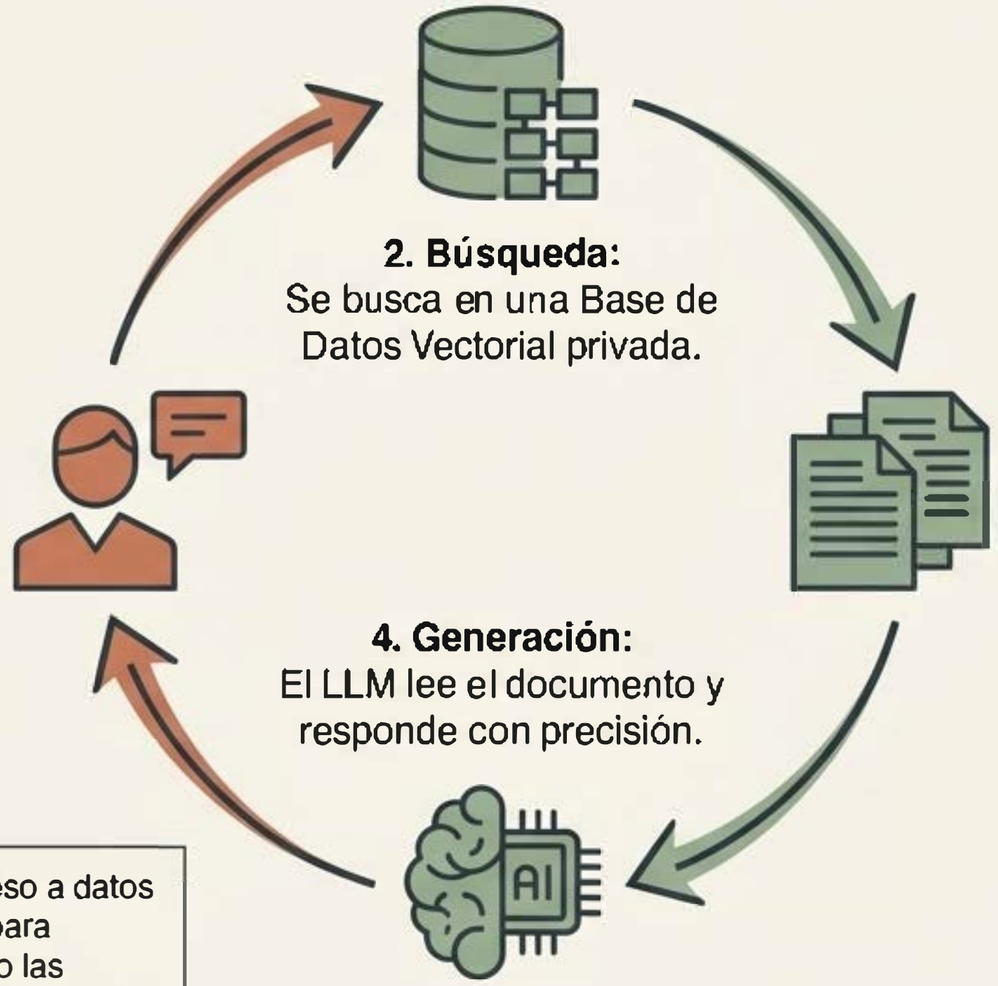

2. Búsqueda:
Se busca en una Base de Datos Vectorial privada.

1. Pregunta: El usuario hace una consulta.

3. Recuperación:
Se extrae el contenido interno relevante.

4. Generación:
El LLM lee el documento y responde con precisión.

La gran ventaja: Otorga al modelo acceso a datos empresariales actualizados y privados para fundamentar sus respuestas, eliminando las alucinaciones sin el enorme costo de reentrenarlo.

Nivel 3: Ajuste Fino (Fine-Tuning)

- A diferencia del RAG o el Prompting, el Fine-tuning modifica permanentemente la estructura interna del cerebro de la IA.
- Se utiliza un conjunto de datos más pequeño pero altamente especializado.
- Beneficios: Mejora radical del rendimiento en tareas muy de nicho, enseña un estilo o formato de salida único, y hace que el sistema sea más rápido.